

Segmentação de Clientes de Cartão de Crédito por Meio de Técnicas de Agrupamento Não Supervisionado: uma Análise Comparativa entre K-Means e Clusterização Hierárquica Aglomerativa

Gustavo Silveira Dias
Instituto Federal de Minas Gerais (IFMG) – Campus Bambuí

RESUMO

A segmentação de clientes é uma etapa fundamental para a gestão de risco de crédito e para estratégias de marketing no setor financeiro. Este artigo apresenta o desenvolvimento, a implementação e a avaliação de uma solução de aprendizado não supervisionado para segmentar clientes de cartão de crédito, utilizando a base *Default of Credit Card Clients* (UCI Machine Learning Repository, 30.000 registros). Foram aplicadas as técnicas K-Means e Clusterização Hierárquica Aglomerativa (ligação de Ward) sobre seis variáveis comportamentais e demográficas construídas a partir dos dados brutos. A seleção do modelo utilizou o Método do Cotovelo e o Coeficiente de Silhueta, resultando em $k = 4$ como número ótimo de clusters (silhueta média = 0,273). Os grupos obtidos revelam taxas de inadimplência marcadamente distintas, variando de 14,7% a 61,1%, evidenciando que a segmentação não supervisionada, por si só, captura um forte sinal de risco sem utilizar o rótulo-alvo. Os resultados são validados pelos índices Davies-Bouldin e Calinski-Harabasz e comparados por meio do Índice de Rand Ajustado, discutindo-se ao final as implicações práticas para estratégias de crédito, cobrança e marketing direcionado.

1 INTRODUÇÃO

O crescimento do uso de cartões de crédito como instrumento de consumo trouxe, junto de seus benefícios, um desafio recorrente para instituições financeiras: a gestão de risco de inadimplência (JANTSCH *et al.*, 2021). Compreender o comportamento financeiro dos clientes não apenas de forma individual, mas por meio de perfis coletivos permite que bancos e financeiras direcionem melhor suas políticas de concessão de crédito, cobrança e relacionamento (ANSARI; RIASI, 2016).

Diferentemente de modelos supervisionados de previsão de inadimplência, que exigem rótulos históricos e buscam prever diretamente se um cliente entrará em *default*, técnicas de agrupamento *clustering* permitem identificar, de forma exploratória e não supervisionada, grupos homogêneos de clientes com base em similaridades em seu comportamento de uso do crédito (HO HA; KRISHNAN, 2012). Essa abordagem

é particularmente útil em cenários de segmentação de carteira, definição de políticas diferenciadas de limite e desenho de campanhas de marketing personalizadas, sem depender exclusivamente do rótulo de inadimplência (YANIK; ELMORSY, 2019).

Este trabalho tem como objetivo desenvolver, implementar e avaliar uma solução computacional de agrupamento aplicada à base pública *Default of Credit Card Clients*, disponibilizada pelo *UCI Machine Learning Repository* (YEH; LIEN, 2009). Para a construção dos agrupamentos são empregados dois algoritmos amplamente utilizados na literatura: o algoritmo *K-Means*, originalmente proposto por MacQueen (MACQUEEN, 1967a) e posteriormente aprimorado quanto à estratégia de inicialização por Arthur e Vassilvitskii (ARTHUR; VASSILVITSKII, 2007a), e a Clusterização Hierárquica Aglomerativa utilizando o método de ligação de Ward (WARD, 1963).

A determinação da quantidade adequada de clusters é realizada por meio da combinação de um método heurístico e índices de validação interna. Inicialmente, utiliza-se o Método do Cotovelo (*Elbow Method*) para analisar a redução da soma dos erros quadráticos intra-cluster (*Within-Cluster Sum of Squares – WCSS*) em função do número de grupos. Em seguida, são empregados o Coeficiente de Silhueta (ROUSSEAU, 1987), o Índice de Davies-Bouldin (DAVIES; BOULDIN, 1979) e o Índice de Calinski-Harabasz (CALÍNSKI; HARABASZ, 1974), amplamente reconhecidos na literatura como medidas para avaliação da qualidade de agrupamentos.

Após a obtenção da configuração considerada mais adequada, os clusters são caracterizados com base nas variáveis comportamentais dos clientes e analisados quanto à sua relação com a taxa observada de inadimplência presente na base de dados. Ressalta-se que a variável de inadimplência é utilizada exclusivamente como critério de validação externa (*a posteriori*), não participando do processo de treinamento dos algoritmos de agrupamento, preservando assim o caráter não supervisionado da abordagem.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica sobre aprendizado não supervisionado e métricas de avaliação de agrupamentos; a Seção 3 descreve a metodologia adotada; a Seção 4 detalha a base de dados e o pré-processamento; a Seção 5 apresenta a solução proposta; a Seção 6 discute os experimentos e resultados obtidos; e a Seção 7 traz as conclusões e trabalhos futuros.

2 FUNDAMENTOS TEÓRICOS

2.1 Aprendizado Não Supervisionado e Agrupamento

O aprendizado não supervisionado compreende um conjunto de técnicas que buscam identificar estruturas ou padrões em dados não rotulados (HO HA;

KRISHNAN, 2012). Dentre essas técnicas, o agrupamento tem como objetivo particionar um conjunto de observações em grupos, de modo que os elementos pertencentes a um mesmo grupo sejam mais similares entre si do que em relação aos elementos dos demais grupos (JAIN, 2010). A similaridade entre as observações é geralmente definida por uma métrica de distância, sendo a distância euclidiana uma das mais utilizadas em espaços de atributos numéricos padronizados (MACQUEEN, 1967b).

2.2 K-Means

O algoritmo K-Means é um método particional que busca minimizar a soma das distâncias quadráticas intra-cluster (Inércia), definida por:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (1)$$

em que C_i representa o i -ésimo cluster e μ_i o seu centróide. O algoritmo é iterativo: (i) inicializa-se k centróides; (ii) cada observação é atribuída ao centróide mais próximo; (iii) os centróides são recalculados como a média das observações de cada grupo; (iv) os passos (ii) e (iii) são repetidos até a convergência. Utilizou-se a inicialização *k-means++* (ARTHUR; VASSILVITSKII, 2007b), que seleciona centróides iniciais de forma probabilística para acelerar a convergência e reduzir a sensibilidade à inicialização aleatória.

2.3 Clusterização Hierárquica Aglomerativa

A clusterização hierárquica aglomerativa constrói uma hierarquia de agrupamentos de forma *bottom-up*: inicialmente, cada observação é seu próprio cluster; a cada passo, os dois clusters mais próximos são fundidos, até que reste um único cluster ou o número desejado de grupos seja atingido. O critério de ligação de Ward (WARD, 1963), adotado neste trabalho, funde a cada passo os clusters que produzem o menor aumento na soma dos quadrados intra-cluster, sendo funcionalmente análogo ao critério de otimização do K-Means, o que favorece a comparação entre os dois métodos. O resultado desse processo pode ser visualizado por meio de um dendrograma.

2.4 Métricas de Validação de Agrupamentos

Como o agrupamento é uma tarefa não supervisionada, a avaliação da qualidade dos clusters depende de métricas internas, calculadas a partir da própria estrutura dos dados:

- **Coefficiente de Silhueta:** proposto por (ROUSSEEUW, 1987), mede, para cada observação, o quão bem ela se ajusta ao seu próprio cluster em comparação ao cluster vizinho mais próximo. Seu valor varia entre -1 e 1 , sendo que valores mais elevados indicam agrupamentos de melhor qualidade.
- **Índice de Davies-Bouldin:** desenvolvido por (DAVIES; BOULDIN, 1979), avalia a razão entre a dispersão intra-cluster e a separação entre os clusters. Quanto menor o índice, melhor é a qualidade do agrupamento.
- **Índice de Calinski-Harabasz:** proposto por (CALIŃSKI; HARABASZ, 1974), corresponde à razão entre a dispersão entre clusters e a dispersão interna de cada grupo. Valores mais elevados indicam clusters mais compactos e bem separados.
- **Índice de Rand Ajustado (ARI):** introduzido por (HUBERT; ARABIE, 1985), mede o grau de concordância entre duas partições de um mesmo conjunto de dados, corrigindo o resultado pelo efeito do acaso. Neste trabalho, esse índice é utilizado para comparar as partições obtidas pelos algoritmos K-Means e Clusterização Hierárquica.

2.5 Trabalhos Relacionados

A base *Default of Credit Card Clients* foi originalmente introduzida por Yeh e Lien (YEH; LIEN, 2009), que compararam técnicas supervisionadas (redes neurais, árvores de decisão, regressão logística, entre outras) para prever a inadimplência de clientes taiwaneses. Desde então, o conjunto tem sido amplamente utilizado como *benchmark* para classificação de risco de crédito. Trabalhos como o de Martinho e Pais-Magalhães (MARTINHO; PAIS-MAGALHÃES, 2020) discutem especificamente a aplicação de técnicas de agrupamento para segmentação de clientes bancários como etapa complementar à análise de risco de crédito, argumentando que perfis de comportamento revelados por *clustering* auxiliam decisões de concessão e monitoramento que modelos puramente preditivos não capturam isoladamente. O presente trabalho se diferencia por aplicar e comparar diretamente dois algoritmos de agrupamento (K-Means e hierárquico aglomerativo) sobre a base de crédito, validando os grupos obtidos frente à taxa real de inadimplência disponível na base.

3 METODOLOGIA

A metodologia adotada neste trabalho baseia-se nas etapas clássicas do processo de Descoberta de Conhecimento em Bases de Dados *Knowledge Discovery in Databases* (KDD), adaptadas ao contexto de aprendizado não supervisionado e

análise de agrupamentos. O processo foi estruturado nas seguintes etapas:

- a) **Coleta e pré-processamento dos dados:** obtenção da base de dados, verificação da existência de registros duplicados, tratamento de inconsistências e adequação das variáveis para a etapa de análise;
- b) **Engenharia de atributos:** criação de variáveis derivadas capazes de representar de forma mais adequada o comportamento financeiro dos clientes, incluindo médias de faturas e pagamentos, taxa de utilização do limite de crédito e quantidade de meses com atraso no pagamento, calculadas a partir do histórico de seis meses disponível na base;
- c) **Padronização dos dados:** aplicação da normalização por *z-score* nas variáveis numéricas, reduzindo o efeito de diferenças de escala entre os atributos e evitando que variáveis de maior magnitude, como o limite de crédito, exercessem influência desproporcional no cálculo das distâncias;
- d) **Determinação do número de clusters:** avaliação de diferentes valores de k , variando de 2 a 10, por meio do Método do Cotovelo e do Coeficiente de Silhueta, visando identificar a configuração mais adequada para o particionamento dos dados;
- e) **Treinamento dos modelos:** aplicação dos algoritmos K-Means e Clusterização Hierárquica Aglomerativa utilizando o número de clusters previamente definido;
- f) **Validação interna:** avaliação da qualidade dos agrupamentos por meio do Coeficiente de Silhueta, do Índice de Davies-Bouldin e do Índice de Calinski-Harabasz. Adicionalmente, foi calculado o Índice de Rand Ajustado (ARI) para mensurar a concordância entre as partições produzidas pelos dois algoritmos;
- g) **Caracterização dos clusters:** análise descritiva dos perfis obtidos, considerando as principais características de cada grupo e sua relação com a taxa real de inadimplência presente na base de dados. Ressalta-se que essa informação foi empregada exclusivamente como critério de validação externa (*a posteriori*), não sendo utilizada durante o processo de agrupamento.

Toda a implementação foi desenvolvida em Python 3, utilizando as bibliotecas `pandas` para manipulação dos dados, `numpy` para computação numérica, `scikit-learn` para implementação dos algoritmos de aprendizado de máquina, `scipy` para operações estatísticas, e `matplotlib` e `seaborn` para a geração de gráficos e visualizações.

4 BASE DE DADOS

A base utilizada é a *Default of Credit Card Clients*, disponibilizada publicamente pelo UCI Machine Learning Repository (YEH; LIEN, 2009), contendo registros de 30.000 clientes de cartão de crédito de Taiwan, com histórico de abril a setembro de 2005. A base original possui 25 colunas, incluindo dados demográficos (sexo, escolaridade, estado civil, idade), limite de crédito, histórico de status de pagamento, valores de fatura e valores pagos nos últimos seis meses, além do rótulo binário de inadimplência no mês seguinte.

4.1 Pré-processamento

Após a remoção da coluna ID e de 35 registros duplicados, restaram 29.965 observações válidas. As variáveis categóricas (*SEX*, *EDUCATION*, *MARRIAGE*) foram renomeadas para rótulos legíveis, agrupando-se categorias residuais ou não documentadas em Outros.

A partir das seis colunas de fatura mensal e das seis colunas de pagamento mensal, foram derivadas as seguintes variáveis agregadas, utilizadas como base para o agrupamento:

- *media_fatura*: média das faturas dos últimos seis meses;
- *media_pagamento*: média dos valores pagos nos últimos seis meses;
- *taxa_utilizacao*: razão entre a média da fatura e o limite de crédito, limitada ao intervalo $[0, 1]$;
- *qtd_atrasos*: número de meses, dentre os últimos seis, em que o status de pagamento indicou atraso ($\text{status} \geq 1$).

Essas variáveis, somadas ao limite de crédito e à idade, compuseram o conjunto final de seis atributos utilizados no agrupamento: *limite_credito*, *idade*, *media_fatura*, *media_pagamento*, *taxa_utilizacao* e *qtd_atrasos*. A Tabela 1 apresenta as estatísticas descritivas dessas variáveis após a limpeza dos dados. A taxa de inadimplência geral observada na base tratada foi de 22,13%, valor mantido **fora** do processo de agrupamento e utilizado apenas na etapa de validação externa dos clusters (Seção 6).

Tabela 1 – Estatísticas descritivas das variáveis selecionadas (n = 29.965)

	Limite (R\$)	Idade	Média fatura	Média pgto.	Tx. utiliz.	Qtd. atrasos
Média	167.442,01	35,49	45.029,33	5.281,30	0,37	0,83
Desvio-padrão	129.760,14	9,22	63.279,07	10.142,31	0,34	1,55
Mínimo	10.000,00	21	-56.043,17	0,00	0,00	0
Mediana	140.000,00	34	21.110,83	2.400,00	0,29	0
Máximo	1.000.000,00	79	877.313,83	627.344,33	1,00	6

Todas as variáveis numéricas foram padronizadas *z-score* antes do agrupamento, de modo que cada atributo passou a ter média 0 e desvio-padrão 1, condição necessária para que variáveis de diferentes escalas como limite de crédito na casa de centenas de milhares e quantidade de atrasos (0 a 6) contribuíssem de forma equilibrada para o cálculo das distâncias euclidianas utilizadas pelos algoritmos.

5 SOLUÇÃO PROPOSTA

A solução proposta consiste em um *pipeline* de agrupamento composto pelas seguintes etapas, implementadas de forma reproduzível em um script Python.

- a) Leitura e pré-processamento da base, conforme descrito na Seção 4;
- b) Padronização das seis variáveis selecionadas via `StandardScaler`;
- c) Busca do número ideal de clusters k , testando k de 2 a 10 com K-Means (`k-means++`, $n_init = 10$), calculando para cada k a inércia, a silhueta média, o índice de Davies-Bouldin e o índice de Calinski-Harabasz;
- d) Treinamento final do K-Means com o k escolhido ($n_init = 20$ para maior estabilidade);
- e) Treinamento da Clusterização Hierárquica Aglomerativa (ligação de Ward) com o mesmo k ;
- f) Comparação dos dois algoritmos por meio das métricas internas e do Índice de Rand Ajustado;
- g) Caracterização de cada cluster por meio das médias das variáveis originais, da distribuição de clientes e da taxa de inadimplência observada.

5.1 Observação metodológica sobre escalabilidade

A Clusterização Hierárquica Aglomerativa apresenta complexidade temporal de $O(n^2 \log n)$ e complexidade espacial de $O(n^2)$, tornando sua aplicação aos 29.965 registros da base inviável em ambientes com recursos limitados de memória. Assim, seguindo prática comum na literatura para bases de maior porte, o algoritmo foi aplicado a uma amostra aleatória de 5.000 clientes, enquanto o K-Means cuja complexidade é $O(n \cdot k \cdot i)$, sendo i o número de iterações foi treinado sobre a base completa. Essa decisão é discutida como limitação na Seção 7.

Para visualizar os agrupamentos em duas dimensões, utilizou-se a Análise de Componentes Principais (PCA), projetando as seis variáveis padronizadas nos dois primeiros componentes principais.

6 EXPERIMENTOS E RESULTADOS

6.1 Determinação do Número de Clusters

A Figura 1 apresenta os resultados do Método do Cotovelo (inércia) e do Coeficiente de Silhueta para k variando de 2 a 10. A Tabela 2 resume os valores obtidos para todas as métricas de validação.




Figura 1 – Método do Cotovelo e Coeficiente de Silhueta para $k \in \{2, \dots, 10\}$.

Tabela 2 – Métricas de validação interna do K-Means por número de clusters

k	Inércia	Silhueta	Davies-Bouldin	Calinski-Harabasz
2	141.820,26	0,2551	1,6749	8.022,07
3	116.000,20	0,2686	1,4148	8.238,23
4	98.318,50	0,2729	1,2654	8.275,72
5	87.646,97	0,2304	1,2966	7.874,28
6	77.278,81	0,2698	1,1250	7.948,22
7	68.298,99	0,2584	1,1036	8.150,57
8	63.466,62	0,2579	1,1075	7.843,72
9	58.855,21	0,2593	1,0496	7.694,16
10	55.103,38	0,2605	1,0189	7.531,34

Observa-se que a curva de inércia (cotovelo) não apresenta uma quebra abrupta e isolada, comportamento comum em dados de comportamento financeiro real, nos quais os grupos não são perfeitamente esféricos ou igualmente espaçados. O Coeficiente de Silhueta, por sua vez, atinge seu valor máximo em $k = 4$ (0,2729), sendo também o ponto em que o índice de Calinski-Harabasz é máximo (8.275,72) e o Davies-Bouldin apresenta um valor competitivo (1,2654), embora não seja o mínimo

global da série (que ocorre em $k = 9$ e $k = 10$, com grupos mais numerosos e de menor interpretabilidade prática). Diante da convergência entre Silhueta e Calinski-Harabasz e considerando a interpretabilidade do resultado para fins de segmentação de negócio, adotou-se $k = 4$ como número final de clusters.

6.2 Comparação entre K-Means e Clusterização Hierárquica

A Tabela 3 apresenta a comparação entre os dois algoritmos treinados com $k = 4$. O K-Means foi treinado sobre a base completa ($n = 29.965$), enquanto o algoritmo hierárquico foi treinado sobre uma amostra aleatória de 5.000 clientes (ver Seção 5).

Tabela 3 – Comparação entre K-Means e Clusterização Hierárquica ($k = 4$)

Métrica	K-Means	Hierárquico
n de observações	29.965	5.000 (amostra)
Silhueta média	0,2731	0,2038
Davies-Bouldin	1,2652	1,2252
Calinski-Harabasz	8.275,73	1.034,13

O K-Means apresentou desempenho superior ao método hierárquico tanto na Silhueta média (0,2731 contra 0,2038) quanto no índice de Calinski-Harabasz, o que é esperado, já que o K-Means otimiza diretamente a compactação intra-cluster que essas métricas privilegiam. O Índice de Rand Ajustado entre as duas partições (calculado sobre a amostra comum de 5.000 clientes) foi de 0,4807, indicando concordância moderada: os dois algoritmos capturam uma estrutura de agrupamento semelhante, mas não idêntica, o que é consistente com a natureza distinta dos critérios de otimização (centróides versus fusões sucessivas por variância). A Figura 2 apresenta o dendrograma obtido para uma sub-amostra de 300 clientes, evidenciando visualmente a formação de quatro grandes grupos.




Figura 2 – Dendrograma da Clusterização Hierárquica (amostra $n = 300$, ligação de Ward).

A Figura 3 apresenta a projeção dos clusters de ambos os algoritmos nos dois primeiros componentes principais, que juntos explicam 57,0% da variância total dos dados (29,2% e 27,7%, respectivamente). Observa-se razoável separação visual entre os grupos, ainda que com sobreposição nas regiões de fronteira, esperada em dados de comportamento financeiro real, cujas classes não são linearmente separáveis.




Figura 3 – Projeção PCA dos clusters obtidos por K-Means e Clusterização Hierárquica.

A Figura 4 apresenta a análise de silhueta detalhada por cluster para o K-Means (amostra de 3.000 clientes), mostrando que os clusters 0, 1 e 2 possuem coeficientes de silhueta relativamente homogêneos e predominantemente positivos, enquanto o cluster 3 (discutido a seguir como o grupo de maior risco) apresenta maior variabilidade interna, refletindo a heterogeneidade dos clientes com histórico de atraso.




Figura 4 – Análise de silhueta por cluster – K-Means (amostra $n = 3.000$).

6.3 Caracterização dos Clusters

A Tabela 4 apresenta o perfil médio de cada cluster obtido pelo K-Means, incluindo o tamanho relativo do grupo e a taxa de inadimplência real observada – esta última utilizada exclusivamente como validação externa *a posteriori*, não tendo sido utilizada no treinamento do modelo.

Tabela 4 – Perfil médio dos clusters (K-Means, $k = 4$)

Variável	Cluster 0	Cluster 1	Cluster 2	Cluster 3
Limite de crédito (R\$)	75.819,88	217.720,57	323.557,46	80.119,64
Idade (anos)	34,3	36,0	37,6	34,9
Média da fatura (R\$)	49.140,92	13.046,04	183.062,72	44.683,23
Média de pagamento (R\$)	3.315,82	4.234,54	20.033,66	2.204,49
Taxa de utilização	0,66	0,07	0,61	0,61
Qtd. de atrasos (0–6)	0,39	0,33	0,34	4,59
Nº de clientes	9.516	14.043	2.979	3.427
% da carteira	31,8%	46,9%	9,9%	11,4%
Tx. de inadimplência	19,74%	15,80%	14,74%	61,10%

Com base nesse perfil, os quatro clusters podem ser interpretados como:

- **Cluster 1 – “Bons pagadores conservadores” (46,9% da carteira):** maior grupo, com limite de crédito elevado (R\$ 217.720,57 em média), porém a menor taxa de utilização do limite (7%) e a menor taxa de ina-

inadimplência entre os grupos com utilização baixa (15,80%). Representa o perfil de menor risco relativo entre os clientes de maior porte;

- **Cluster 2 – “Alto poder aquisitivo e alta movimentação” (9,9% da carteira):** menor grupo, com o maior limite de crédito (R\$ 323.557,46), maiores valores médios de fatura e de pagamento, e a *menor* taxa de inadimplência observada (14,74%), mesmo com utilização moderada do limite (61%). Indica clientes de alta renda com comportamento de pagamento consistente;
- **Cluster 0 – “Uso moderado, risco intermediário” (31,8% da carteira):** limite de crédito mais baixo (R\$ 75.819,88), alta utilização do limite (66%) e taxa de inadimplência intermediária (19,74%);
- **Cluster 3 – “Alto risco / atrasos recorrentes” (11,4% da carteira):** grupo com limite de crédito baixo, utilização de 61%, mas com uma média de **4,59 meses em atraso** nos últimos seis meses – valor drasticamente superior aos demais grupos ($\leq 0,39$) – e taxa de inadimplência de **61,10%**, quase três vezes a média geral da base (22,13%).

A Figura 5 ilustra graficamente o perfil padronizado (z-score) de cada cluster, evidenciando o comportamento atípico do Cluster 3 na variável `qtd_atrasos`, e a Figura 6 apresenta diretamente a taxa de inadimplência por cluster em contraste com a média geral da base.




Figura 5 – Perfil médio padronizado (z-score) das variáveis por cluster (K-Means).




Figura 6 – Taxa de inadimplência observada por cluster, comparada à média geral da base (22,13%).

6.4 Discussão

O resultado mais relevante deste trabalho é a evidência de que a variável mais discriminante entre os clusters não é o limite de crédito nem o volume financeiro movimentado, mas sim a **quantidade de meses em atraso** nos últimos seis meses. Isso sugere que o histórico recente de atraso é um sinal comportamental muito mais forte de risco futuro do que características estáticas como renda aparente (aproximada pelo limite de crédito) ou volume de gastos. Esse achado é consistente com a literatura de risco de crédito, na qual variáveis comportamentais recentes (*behavior score*) tendem a superar variáveis cadastrais (*application score*) na previsão de inadimplência de curto prazo.

Chama atenção também que o Cluster 2, de clientes com maior limite e maior movimentação financeira, apresentou a *menor* taxa de inadimplência entre os quatro grupos, contrariando a intuição de que maior exposição financeira implicaria necessariamente maior risco. Isso reforça a importância de segmentar clientes por padrão comportamental multivariado, e não apenas por variáveis isoladas como limite de crédito.

Do ponto de vista de negócio, os resultados sugerem estratégias diferenciadas: o Cluster 3 seria prioritário para ações de cobrança preventiva e revisão de limite; o Cluster 1, por sua vez, representa uma base ampla e de baixo risco, potencialmente elegível para ofertas de aumento de limite ou produtos de maior valor agregado; o Cluster 2 representa um segmento premium de baixo risco relativo, adequado para estratégias de fidelização; e o Cluster 0 representa um grupo intermediário que pode

se beneficiar de monitoramento próximo, dada sua alta utilização de limite.

7 CONCLUSÃO

Este trabalho desenvolveu, implementou e avaliou uma solução de agrupamento não supervisionado para segmentação de clientes de cartão de crédito, comparando K-Means e Clusterização Hierárquica Aglomerativa sobre a base pública *Default of Credit Card Clients*. A seleção de $k = 4$, fundamentada no Coeficiente de Silhueta e no índice de Calinski-Harabasz, resultou em grupos com perfis de risco claramente distintos, validados externamente pela taxa real de inadimplência: de 14,74% no cluster de menor risco a 61,10% no cluster de maior risco – uma diferença de mais de quatro vezes obtida sem que o algoritmo tivesse qualquer acesso ao rótulo de inadimplência durante o treinamento.

Como principais limitações do estudo, destacam-se: (i) a restrição computacional que impediu a aplicação da Clusterização Hierárquica sobre a base completa, exigindo o uso de uma amostra de 5.000 registros para esse algoritmo; (ii) o uso de apenas seis variáveis agregadas, que, embora suficientes para revelar padrões relevantes, podem ocultar nuances presentes no histórico mês a mês; e (iii) a concordância apenas moderada ($ARI = 0,4807$) entre os dois algoritmos, que reforça a necessidade de análise crítica sobre qual método é mais adequado a cada aplicação de negócio, em vez de assumir um único agrupamento como “verdade absoluta”.

Como trabalhos futuros, sugere-se: (i) a aplicação de algoritmos de agrupamento escaláveis para grandes volumes, como Mini-Batch K-Means ou BIRCH, permitindo comparação direta com o método hierárquico sobre a base completa; (ii) a incorporação de variáveis de série temporal (em vez de médias agregadas) por meio de técnicas específicas para dados sequenciais; e (iii) a combinação da segmentação não supervisionada com modelos supervisionados de previsão de inadimplência, avaliando se a variável de cluster melhora o desempenho preditivo quando usada como atributo adicional.

REFERÊNCIAS

ANSARI, A.; RIASI, A. Taxonomy of Marketing Strategies Using Bank Customers' Clustering. **International Journal of Business and Management**, Canadian Center of Science e Education, v. 11, n. 7, p. 106–119, 2016. DOI: 10.5539/ijbm.v11n7p106. Disponível em: <https://doi.org/10.5539/ijbm.v11n7p106>.

ARTHUR, D.; VASSILVITSKII, S. k-means++: The Advantages of Careful Seeding. In: **PROCEEDINGS of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms**. 2007a. p. 1027–1035.

ARTHUR, D.; VASSILVITSKII, S. k-means++: The advantages of careful seeding. **Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms**, p. 1027–1035, 2007b.

CALIŃSKI, T.; HARABASZ, J. A Dendrite Method for Cluster Analysis. **Communications in Statistics**, v. 3, n. 1, p. 1–27, 1974. DOI: 10.1080/03610927408827101.

DAVIES, D. L.; BOULDIN, D. W. A Cluster Separation Measure. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, PAMI-1, n. 2, p. 224–227, 1979. DOI: 10.1109/TPAMI.1979.4766909.

HO HA, S.; KRISHNAN, R. Predicting repayment of the credit card debt. **Computers & Operations Research**, v. 39, n. 4, p. 765–773, 2012. Special Issue on Operational Research in Risk Management. ISSN 0305-0548. DOI: <https://doi.org/10.1016/j.cor.2010.10.032>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S030505481000290X>.

HUBERT, L.; ARABIE, P. Comparing partitions. **Journal of Classification**, v. 2, n. 1, p. 193–218, 1985.

JAIN, A. K. Data clustering: 50 years beyond K-means. **Pattern Recognition Letters**, v. 31, n. 8, p. 651–666, 2010. Award winning papers from the 19th International Conference on Pattern Recognition (ICPR). ISSN 0167-8655. DOI: <https://doi.org/10.1016/j.patrec.2009.09.011>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0167865509002323>.

JANTSCH, L. *et al.* Analysis of Default Risk in Credit Card Use. **Brazilian Journal of Development**, Brazilian Journals Publicações de Periódicos, v. 7, n. 6, p. 62634–62656, 2021. ISSN 2525-8761. DOI: 10.34117/bjdv7n6-576. Disponível em: <https://doi.org/10.34117/bjdv7n6-576>.

MACQUEEN, J. Some Methods for Classification and Analysis of Multivariate Observations. *In*: PROCEEDINGS of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. 1967a. v. 1, p. 281–297.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. *In*: disponível em: <https://api.semanticscholar.org/CorpusID:6278891>.

MARTINHO, V. D.; PAIS-MAGALHÃES, V. Customer segmentation in banking: a clustering-based approach for credit risk analysis. **Journal of Risk Model Validation**, v. 14, n. 2, 2020.

ROUSSEEUW, P. J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7.

WARD, J. H. Hierarchical Grouping to Optimize an Objective Function. **Journal of the American Statistical Association**, v. 58, n. 301, p. 236–244, 1963. DOI: 10.1080/01621459.1963.10500845.

YANIK, S.; ELMORSY, A. SOM approach for clustering customers using credit card transactions. **International Journal of Intelligent Computing and Cybernetics**, v. 12, n. 3, p. 372–388, 2019. ISSN 1756-378X. DOI: <https://doi.org/10.1108/IJICC-11-2018-0157>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1756378X19000074>.

YEH, I.-C.; LIEN, C.-h. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. **Expert Systems with Applications**, v. 36, 2, Part 1, p. 2473–2480, 2009. ISSN 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2007.12.020>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0957417407006719>.